MÉTODOS ESTADÍSTICOS PARA INTELIGENCIA ARTIFICIAL

- UNIDAD 1: NOCIONES DE PROBABILIDADES. ESTADÍSTICA DESCRIPTIVA
- UNIDAD 2: TEST DE HIPÓTESIS
- UNIDAD 3: REGRESIÓN
- UNIDAD 4: ESTADÍSTICA NO PARAMÉTRICA

Universidad Nacional ARTURO JAURETCHE

TICAPPS | UNAJ
Programa Tecnologías de la Información y la Comunicación (TICs) en Aplicaciones de Interés Social

MÉTODOS ESTADÍSTICOS PARA INTELIGENCIA ARTIFICIAL

- UNIDAD 1: NOCIONES DE PROBABILIDADES. ESTADÍSTICA DESCRIPTIVA
- UNIDAD 2: TEST DE HIPÓTESIS
- **UNIDAD 3: REGRESIÓN**
- UNIDAD 4: ESTADÍSTICA NO PARAMÉTRICA

Universidad Nacional ARTURO JAURETCHE

TICAPPS | UNAJ
Programa Tecnologías de la Información y la Comunicación (TICs) en Aplicaciones de Interés Social

Unidad 3 - Parte 3

Regresión Lineal Múltiple

Objetivos de esta presentación

- Extender el modelo lineal simple a más de una variable explicativa.
- Interpretar los coeficientes en un modelo múltiple.
- Evaluar la significancia global y parcial de las variables.
- Realizar un test de hipótesis sobre un modelo lineal múltiple
- Aplicar el modelo en Python y analizar resultados.

Resumen

Modelo de regresión lineal múltiple

Estimación de mínimos cuadrados

Evaluación de modelos

Resumen

Modelo de regresión lineal múltiple

Estimación de mínimos cuadrados

Evaluación de modelos

Modelo de regresión lineal múltiple

- En muchas ocasiones, una variable y depende de más de una variable, digamos $x_1, x_2, x_3, \ldots, x_k$.
- Cuando una sola variable no explica bien la variabilidad, se debe incorporar más información.
- Algunos ejemplos:
- Predecir el precio de una vivienda (y) que, en principio, puede ser una función de muchas cosas (ejemplo 22). Podríamos estar interesados en evaluar su relación con: la superficie total (x_1), la cantidad de habitaciones (x_2) y la ubicación (x_3). En ese caso, se piensa que esas variables explican la variable dependiente y, se les dice **variables explicativas** (independientes)[1].

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

[1]En el ejemplo 22, otra variable independiente es la antigüedad de la vivienda.

Modelo de regresión lineal múltiple

- Otra situación que puede ocurrir, es cuando hay una relación no lineal. En algunos casos es linealizable.
- Tomemos un ejemplo sencillo, pensemos en la posición de una partícula lanzada verticalmente con una velocidad inicial v_0 desde una altura h, se cumple: $y = h + v_0 t - \frac{1}{2} g t^2$ (aquí t es el tiempo y g la aceleración de la gravedad). Si llamamos $x_1 = t$ y $x_2 = t^2$; y $\beta_0 = h$, $\beta_1 = v_0$, $\beta_2 = -\frac{1}{2} g$ entonces queda un modelo lineal:



$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

Modelo de regresión lineal múltiple

- En definitiva, pensamos en un modelo del tipo:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + E \qquad (1)$$

- Aquí nuevamente consideramos que las variables independientes (explicativas) x_i son determinísticas.
- A los parámetros β_i se los denomina **coeficientes de regresión**. Cada $\beta_i$representa el cambio esperado en y manteniendo las demás variables constantes. Permite distinguir el efecto individual vs. el efecto conjunto.
- Lo probabilístico lo pone E, que es un error similar al propuesto en la Ec. (1) de la presentación 3.1. Su esperanza es $E\{E\} = 0$. Por lo tanto:

$$E\{Y\} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k \qquad (2)$$

Suposiciones del modelo de regresión lineal múltiple

- Linealidad
- Independencia de los errores
- Homocedasticidad
- Normalidad de los errores
- No colinealidad entre las x_i

Suposiciones del modelo de regresión lineal múltiple

❖ Linealidad

- Se asume que la relación entre cada variable independiente x_i y la variable dependiente y es lineal, es decir que el modelo puede escribirse como una combinación lineal de coeficientes:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + E$$

- Puede verificarse mediante:
  - Gráfico de residuos vs. valores ajustados (sns.residplot).

  En este caso, si el modelo es lineal, los residuos no deben mostrar ningún patrón, deben dispersarse aleatoriamente alrededor de cero. Si aparece una forma de U, ∩, ondas o tendencia, significa que la relación entre las variables no es lineal y el modelo lineal no captura la estructura real de los datos.

Suposiciones del modelo de regresión lineal múltiple

❖ Independencia de los errores

- Los errores (e_i) deben ser independientes entre sí, es decir, no están correlacionados entre sí.
- Esto significa que el valor del error en una observación no depende del error en otra. No se cumple en series temporales o datos secuenciales.
- Puede verificarse mediante:
  - Test de Durbin–Watson* (valores cercanos a 2 indican independencia). Se lo puede ver con modelo.summary().
  - Gráfico de residuos vs. tiempo.

*https://www.investopedia.com/terms/d/durbin-watson-statistic.asp
https://corporatefinanceinstitute.com/resources/data-science/durbin-watson-statistic/

Suposiciones del modelo de regresión lineal múltiple

- **Homocedasticidad (varianza constante de los errores)**

- Se asume que la varianza de los errores es constante: $(V(e_i) = \sigma^2)$.

- Puede verificarse mediante:
  - Gráfico de residuos vs. valores ajustados (no debe observarse forma de embudo).

- Se puede corregir aplicando transformaciones (por ejemplo logaritmo o raíz cuadrada de Y).

Suposiciones del modelo de regresión lineal simple

❖ **Normalidad de los errores**

- Los errores deben seguir una distribución aproximadamente Normal con media 0 y varianza constante: $e_i \sim N(0, \sigma^2)$.

- Puede verificarse mediante:
  - Gráfico de residuos vs. valores ajustados (los residuos deben estar centrados alrededor de la línea horizontal en 0).
  - Histograma (se evalúa si la distribución de los residuos está centrada en 0).
  - QQ-plot (ideal para ver si la mediana es 0).

- Se puede corregir aplicando test no paramétricos.

Suposiciones del modelo de regresión lineal múltiple

❖ **No colinealidad entre las x_i**

- Las variables explicativas no deben estar fuertemente correlacionadas entre sí.
- Una alta correlación lineal entre predictores hace que sea difícil separar sus efectos individuales sobre Y.
- Puede verificarse mediante el cálculo del **Factor de Inflación de la Varianza** (**VIF:** Variance Inflation Factor), donde los valores > 5 (o 10) indican problemas, los coeficientes estimados pueden volverse inestables y sus errores estándar inflarse.
- Se puede corregir eliminando o combinando variables correlacionadas, o aplicar métodos de regularización (Ridge, Lasso).

Resumen

Modelo de regresión lineal múltiple

Estimación de mínimos cuadrados

Evaluación de modelos

Estimación de mínimos cuadrados

En lo que sigue generalizaremos lo que vimos en la Presentación 3.1 para un sistema de *k* variables independientes.

Denotemos la i-ésima observación de x_j como x_{ij}, entonces si tomamos n mediciones tendremos datos del tipo:

$$(x_{i1}, x_{i2}, \ldots, x_{ik}, y_i) \text{ para } i = 1, \ldots, n \tag{3}$$

Desarrollemos el caso $k = 2$.

A la Ec. (1) la podemos escribir de forma reducida de la siguiente manera:

$$y_i = \beta_0 + \sum_{j=1}^{2} \beta_j x_{ij} + e_i \text{ para } i = 1, \ldots, n \tag{4}$$

donde e_i es una salida de la variable aleatoria E. Podemos entonces, escribir la **función de mínimos cuadrados**:

$$L = \sum_{i=1}^{n} \left[y_i - \left(\beta_0 + \sum_{j=1}^{2} \beta_j x_{ij} \right) \right]^2 \tag{5}$$

Estimación de mínimos cuadrados

Definida la Ec. (5), lo que resta hacer es minimizarla respecto de los coeficientes de regresión:

$$\left.\frac{\partial L}{\partial \beta_0}\right|_{\hat{\beta}_0,\hat{\beta}_1,\hat{\beta}_2} = -2\sum_{i=1}^{n}\left[y_i - \left(\hat{\beta}_0 + \sum_{j=1}^{2}\hat{\beta}_j x_{ij}\right)\right] = 0$$

$$\left.\frac{\partial L}{\partial \beta_j}\right|_{\hat{\beta}_0,\hat{\beta}_1,\hat{\beta}_2} = -2\sum_{i=1}^{n} x_{ij}\left[y_i - \left(\hat{\beta}_0 + \sum_{j=1}^{2}\hat{\beta}_j x_{ij}\right)\right] = 0$$

Arreglando estas ecuaciones llegamos a las denominadas **Ecuaciones Normales**:

$$\begin{array}{c} n\hat{\beta}_0 + \sum_{i=1}^{n}\hat{\beta}_1 x_{i1} + \sum_{i=1}^{n}\hat{\beta}_2 x_{i2} = \sum_{i=1}^{n} y_i \\ \sum_{i=1}^{n}\hat{\beta}_0 x_{i1} + \sum_{i=1}^{n}\hat{\beta}_{i1} x_{i1}^2 + \sum_{i=1}^{n}\hat{\beta}_{i2} x_{i1}x_{i2} = \sum_{i=1}^{n} x_{i1}y_i \\ \sum_{i=1}^{n}\hat{\beta}_0 x_{i2} + \sum_{i=1}^{n}\hat{\beta}_{i1} x_{i1}x_{i2} + \sum_{i=1}^{n}\hat{\beta}_{i2} x_{i2}^2 = \sum_{i=1}^{n} x_{i2}y_i \end{array} . \qquad (6)$$

Resolviendo este sistema obtenemos la estimación de mínimos cuadrados.

Estimación de mínimos cuadrados: forma matricial

Es conveniente para este tipo de problemas expresar las ecuaciones en forma matricial. Entonces, continuando con $k = 2$ y ahora supongamos que tomamos muestras de tamaño $n = 4$ entonces según la Ec. (4) tenemos:

$$
\begin{aligned}
y_1 &= \beta_0 + \beta_1 x_{11} + \beta_2 x_{12} + e_1 \\
y_2 &= \beta_0 + \beta_1 x_{21} + \beta_2 x_{22} + e_2 \\
y_3 &= \beta_0 + \beta_1 x_{31} + \beta_2 x_{32} + e_3 \\
y_4 &= \beta_0 + \beta_1 x_{41} + \beta_2 x_{42} + e_4
\end{aligned}
$$

reescribiendo de manera matricial queda:

$$
\underbrace{\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix}}_{n\times 1} = \underbrace{\begin{bmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ 1 & x_{31} & x_{32} \\ 1 & x_{41} & x_{42} \end{bmatrix}}_{n\times(k+1)} \underbrace{\begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}}_{(k+1)\times 1} + \underbrace{\begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \end{bmatrix}}_{n\times 1} \Rightarrow \mathbf{y} = \mathbf{X}\beta + \mathbf{e}. \qquad (7)
$$

Estimación de mínimos cuadrados: Matricial

Para operar con la Ec. (7) debemos conocer algunas operaciones matriciales[2]. Para obtener la ecuación equivalente a la Ec. (5) notemos que la suma de los residuos la obtenemos con la siguiente operación:

$$\mathbf{e}^T\mathbf{e} = \begin{bmatrix} e_1 & e_2 & e_3 & e_4 \end{bmatrix} \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \end{bmatrix} = e_1^2 + e_2^2 + e_3^2 + e_4^2, \tag{8}$$

donde la operación ^{T} es la matriz transpuesta. Entonces la función de mínimos cuadrados es:

$$L = \underbrace{(\mathbf{y} - \mathbf{X}\beta)^T}_{\mathbf{e}^T} \underbrace{(\mathbf{y} - \mathbf{X}\beta)}_{\mathbf{e}}, \tag{9}$$

derivando esta ecuación respecto de β se obtiene la forma matricial de la **Ecuación Normal**:

$$\mathbf{X}^T\mathbf{X}\hat{\beta} = \mathbf{X}^T\mathbf{y}, \tag{10}$$

[2]Para una revisión puede consultar en:
https://www.mate.unlp.edu.ar/practicas/49_10_29052020002917.pdf

Estimación de mínimos cuadrados: Matricial

Detengámonos un poco en la Ec. (10).

- Aquí la repetimos para indicar las dimensiones de las matrices:

$$\underbrace{\mathbf{X}^T\mathbf{X}}_{(k+1)\times(k+1)}\ \hat{\beta} = \underbrace{\mathbf{X}^T}_{(k+1)\times n}\ \mathbf{y} \tag{11}$$

por lo tanto, dimensionalmente es correcta.

- Para recordar este resultado es útil pensarlo de la siguiente forma. Supongamos que estudiamos un modelo determinístico del tipo lineal $\mathbf{y} = \mathbf{X}\hat{\beta}$, entonces para "despejar" $\hat{\beta}$ podría realizar la siguiente cuenta. Primero multiplico a izquierda[3] por $\mathbf{X}^T$

$$\mathbf{X}^T\mathbf{y} = \mathbf{X}^T\mathbf{X}\hat{\beta}$$

luego, como ahora $\mathbf{X}^T\mathbf{X}$ es una matriz cuadrada, puedo calcular su inversa, y multiplicar a izquierda nuevamente:

$$\left(\mathbf{X}^T\mathbf{X}\right)^{-1}\mathbf{X}^T\mathbf{y} = \left(\mathbf{X}^T\mathbf{X}\right)^{-1}\mathbf{X}^T\mathbf{X}\hat{\beta} = \hat{\beta} \tag{12}$$

[3]Multiplicar a izquierda o derecha en matrices es diferente al caso de escalares.

Resumen

Modelo de regresión lineal múltiple

Estimación de mínimos cuadrados

Evaluación de modelos

Evaluación del modelo de regresión lineal múltiple

1. Coeficiente de determinación R^2

- Representa la **proporción de la variabilidad de la variable dependiente** y que puede explicarse a partir de las variables independientes incluidas en el modelo.

- Se calcula como: $$R^2 = 1 - \frac{SS_E}{SS_T}$$

donde SS_E es la suma de los cuadrados de los errores y SS_T es la suma de los cuadrados de la diferencia de cada muestra respecto a la media.

- Su valor varía entre 0 y 1:

- $R^2 = 1$ → el modelo explica perfectamente la variabilidad observada.
- $R^2 = 0$ → el modelo no explica nada más allá de la media.

Cuidado!! Agregar variables siempre aumenta R^2 , aunque no necesariamente sean relevantes.

Evaluación del modelo de regresión lineal múltiple

2. Coeficiente de determinación $R^2_{ajustado}$

- Penaliza la inclusión de variables innecesarias.
- Se calcula como: $$R^2_{ajustado} = 1 - \frac{(1-R^2)(n-1)}{n-p-1}$$

donde n es el número de observaciones y p el número de predictores.

- Tiene como ventaja que solo aumenta cuando una nueva variable mejora el modelo más de lo esperado por azar.
- En regresión lineal múltiple se prefiere su uso por sobre R^2 para comparar modelos con diferente cantidad de variables.

Evaluación del modelo de regresión lineal múltiple

3. Test F global

- ¿El modelo explica significativamente a y ?
- El Test F global evalúa si **el modelo en su conjunto** tiene capacidad explicativa significativa.
- Hipótesis:

$$H_0: \beta_1 = \beta_2 = \cdots = \beta_k = 0$$

$$H_1: \text{Al menos una } \beta_i \neq 0$$

- Si el **p-valor asociado al test F** es menor que el nivel de significancia (por ejemplo, 0.05), se **rechaza** H_0 ,concluyendo que el modelo tiene poder explicativo.

La **distribución F** es también conocida como de Fisher-Snedecor.

Evaluación del modelo de regresión lineal múltiple

4. Métricas adicionales de error

- Aunque el modelo sea estadístico, es útil cuantificar el error de predicción:

- **RMSE (Root Mean Squared Error):** mide el error promedio de predicción en las mismas unidades que Y.

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y})^2}$$

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}|$$

- **MAE (Mean Absolute Error):** más robusto frente a valores atípicos.

- Estas métricas permiten comparar modelos sobre conjuntos de validación o con nuevas observaciones.

Multicolinealidad

- Se dice que existe multicolinealidad cuando **dos o más variables explicativas están fuertemente correlacionadas entre sí**.
- Como consecuencia:

- Los coeficientes estimados se pueden volver inestables: pequeños cambios en los datos pueden alterar significativamente los valores de β_i.

- Podemos tener errores estándar inflados: los coeficientes parecen poco significativos (p-valores altos) aunque las variables sí lo sean.

- Difícil interpretación: se pierde la capacidad de aislar el efecto individual de cada predictor.

- La multicolinealidad no afecta el poder predictivo global del modelo, pero sí distorsiona la interpretación estadística de los coeficientes.

Multicolinealidad

¿Cómo detectarla?

- **Matriz de correlaciones:** valores altos ($|r| > 0.8$) entre predictores pueden alertar del problema.

- **Factor de Inflación de la Varianza (VIF):**

$$VIF_i = \frac{1}{(1 - R_i^2)}$$

donde R_i^2 es el coeficiente de determinación al estimar la relación entre X_i sobre las demás variables.

- $VIF = 1$: sin correlación.
- $5 < VIF < 10$: posible multicolinealidad.
- $VIF > 10$: multicolinealidad severa.

En Python, puede calcularse fácilmente con *variance_inflation_factor* de la librería statsmodels.

Multicolinealidad

¿Cómo mitigar la multicolinealidad?

- **Eliminar variables redundantes:** si dos variables aportan información similar, mantener solo una.
- **Combinar variables correlacionadas:** por ejemplo, construir índices o promedios.
- **Aplicar métodos de regularización:**

Ridge Regression (L2): penaliza los coeficientes grandes, estabilizando la estimación.

Lasso Regression (L1): además de estabilizar, puede eliminar variables irrelevantes.

- **Recoger más datos:** en algunos casos, una muestra más grande puede reducir la inestabilidad numérica.

Regresión Lineal en Python

- En Python existen dos alternativas principales para ajustar un modelo lineal.

- La función ***statsmodels.OLS()*** de la librería **statsmodels**, cuyo propósito es el realizar un ajuste estadístico con interpretación completa.

```
# Ajuste del modelo
modelo = sm.OLS(y, X).fit()

# Resumen completo
print(modelo.summary())
```

OLS (Ordinary Least Squares)



El método OLS busca minimizar la suma de los cuadrados de los residuos (la diferencia entre los valores reales y los predichos).

- La salida del código es:
  - Coeficientes estimados
  - Errores estándar
  - Estadísticos t y p-valores
  - Intervalos de confianza
  - R^2 y R^2 ajustado
  - Test F, Durbin-Watson, Jarque-Bera, etc.

Ejemplo 22 utilizando la función statsmodels.OLS()

```python
# ----- Ajuste con statsmodels (OLS) -----
X = data[["superficie", "habitaciones", "antiguedad"]]
X = sm.add_constant(X)  # agrega intercepto
y = data["precio"]

# Ajuste del modelo
modelo = sm.OLS(y, X).fit()

# Resumen completo
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.876
Model:                            OLS   Adj. R-squared:                  0.873
Method:                 Least Squares   F-statistic:                     274.2
Date:                Sun, 12 Oct 2025   Prob (F-statistic):           1.74e-52
Time:                        16:43:44   Log-Likelihood:                -1397.5
No. Observations:                 120   AIC:                             2803.
Df Residuals:                     116   BIC:                             2814.
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
```

Ejemplo 22 utilizando la función statsmodels.OLS()

```python
# ----- Ajuste con statsmodels (OLS) -----
X = data[["superficie", "habitaciones", "antiguedad"]]
X = sm.add_constant(X)  # agrega intercepto
y = data["precio"]

# Ajuste del modelo
modelo = sm.OLS(y, X).fit()

# Resumen completo
print(modelo.summary())
```

```
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       6.041e+04   9552.992      6.324      0.000    4.15e+04    7.93e+04
superficie  1312.7647     50.679     25.903      0.000    1212.388    1413.142
habitaciones 1.649e+04   1872.172      8.808      0.000    1.28e+04    2.02e+04
antiguedad  -863.3354    227.469     -3.795      0.000   -1313.867    -412.804
==============================================================================
Omnibus:                        0.382   Durbin-Watson:                   1.839
Prob(Omnibus):                  0.826   Jarque-Bera (JB):                0.212
Skew:                          -0.101   Prob(JB):                        0.900
Kurtosis:                       3.042   Cond. No.                         523.
==============================================================================
```

Regresión Lineal en Python

- La otra alternativa es usar la función ***LinearRegression()*** de la librería **scikit-learn**, cuyo propósito es tener un enfoque predictivo (entrenamiento, evaluación con R^2, RMSE, etc.). Es más usado en Machine Learning.

```
# Ajuste del modelo
modelo = LinearRegression()
modelo.fit(X, y)


# Coeficientes
print("Intercepto:", modelo.intercept_)
print("Coeficientes:", dict(zip(X.columns, modelo.coef_)))
```

- La salida del código es:
  - Coeficientes estimados
  - R^2

Conclusiones

De la regresión lineal simple a la múltiple

- En esta unidad aprendimos a modelar relaciones lineales entre variables, pasando de un único predictor (x) a varios $(x_1, x_2, \dots, x_k)$.
- La regresión lineal simple nos permitió comprender la idea de pendiente, ordenada al origen y el concepto de “mejor ajuste” mediante mínimos cuadrados.
- La regresión lineal múltiple extendió este razonamiento a más dimensiones, permitiendo analizar efectos combinados y cuantificar la contribución de cada variable.
- Este paso constituye la base conceptual de muchos modelos más complejos en ciencia de datos y aprendizaje automático.

Conclusiones

Limitaciones del modelo lineal

- El modelo lineal múltiple es poderoso, pero se apoya en supuestos fuertes (linealidad, normalidad, independencia).
- En muchos fenómenos reales, las relaciones pueden ser no lineales.
- En esos casos, el modelo lineal puede servir como punto de partida o referencia, pero no captará toda la complejidad del sistema.
- Esta limitación abre el camino hacia:
  - Modelos polinomiales o transformaciones no lineales.
  - Métodos de aprendizaje automático más flexibles (árboles, redes neuronales, boosting, etc.).